

Manifold-Constrained Hyper-Connections (mHC)

Minh Tuan Tran[†]

[†]Neuriton Team

Abstract

Gần đây, các nghiên cứu như Hyper-Connections (HC) đã mở rộng khuôn khổ kết nối thặng dư (residual connections) bằng cách tăng độ rộng của luồng thặng dư và đa dạng hóa các mẫu kết nối, qua đó đạt được những cải thiện hiệu suất đáng kể. Tuy nhiên, sự đa dạng hóa này làm suy yếu bản chất ánh xạ đồng nhất (identity mapping) vốn là nền tảng của kết nối thặng dư, dẫn đến sự mất ổn định trong quá trình huấn luyện, hạn chế khả năng mở rộng, cũng như làm gia tăng đáng kể chi phí truy cập bộ nhớ.

Để khắc phục những hạn chế trên, chúng tôi đề xuất **Manifold-Constrained Hyper-Connections (mHC)**, một khuôn khổ tổng quát nhằm chiếu không gian kết nối thặng dư của HC lên một đa tạp được ràng buộc, qua đó khôi phục tính chất ánh xạ đồng nhất trong khi vẫn duy trì tính biểu đạt của mô hình. Bên cạnh đó, mHC được thiết kế cùng với các tối ưu hóa hạ tầng nghiêm ngặt nhằm đảm bảo hiệu quả tính toán và khả năng mở rộng.

Các thí nghiệm quy mô lớn cho thấy mHC không chỉ cải thiện đáng kể hiệu suất so với HC tiêu chuẩn mà còn mang lại sự ổn định huấn luyện và khả năng mở rộng vượt trội. Chúng tôi tin rằng mHC, với vai trò là một phần mở rộng linh hoạt và thực tiễn của Hyper-Connections, góp phần làm sáng tỏ hơn các nguyên lý thiết kế kiến trúc tô pô và mở ra những hướng nghiên cứu tiềm năng cho sự phát triển của các mô hình nền tảng.

1 Giới thiệu

Kiến trúc mạng nơ-ron sâu đã trải qua sự phát triển nhanh chóng kể từ khi ResNet được giới thiệu. Như được minh họa trong Hình 1(a), cấu trúc của một lớp đơn lẻ có thể được mô hình hóa như sau:

$$x_{l+1} = x_l + \mathcal{F}(x_l, \mathcal{W}_l) \quad (1)$$

Trong đó x_l và x_{l+1} biểu thị đầu vào và đầu ra kích thước C của lớp thứ l , và $\mathcal{F}$ đại diện cho hàm thặng dư. Mặc dù hàm thặng dư $\mathcal{F}$ đã phát triển trong thập kỷ qua bao gồm nhiều hoạt động khác nhau như tích chập (convolution), cơ chế chú ý (attention), và mạng truyền thẳng (feed forward networks), mô hình kết nối thặng dư vẫn giữ nguyên dạng ban đầu. Cùng với sự tiến bộ của kiến trúc Transformer, mô hình này hiện đã tự thiết lập như một yếu tố thiết kế cơ bản trong các mô hình ngôn ngữ lớn (LLMs). Thành công này chủ yếu nhờ vào dạng súc tích của kết nối thặng dư. Quan trọng hơn, nghiên cứu ban đầu đã chỉ ra rằng tính chất ánh xạ đồng nhất của kết nối thặng dư duy trì sự ổn định và hiệu quả trong quá trình huấn luyện quy mô lớn. Bằng cách mở rộng đệ quy kết nối thặng dư qua nhiều lớp, Phương trình (1) cho ra:

$$x_L = x_l + \sum_{i=l}^{L-1} \mathcal{F}(x_i, \mathcal{W}_i) \quad (2)$$

trong đó L và l tương ứng với các lớp sâu hơn và nông hơn. Thuật ngữ ánh xạ đồng nhất đề cập đến chính thành phần x , nhấn mạnh tính chất rằng tín hiệu từ lớp nông hơn ánh xạ trực tiếp đến lớp sâu hơn mà không có bất kỳ sự thay đổi nào.

Gần đây, các nghiên cứu điển hình bởi Hyper-Connections (HC) đã giới thiệu một chiều mới cho kết nối thẳng dư. Kiến trúc lớp đơn của HC được minh họa trong Hình 1(b). Bằng cách mở rộng độ rộng của luồng thẳng dư và tăng cường độ phức tạp kết nối, HC làm tăng đáng kể độ phức tạp tô pô mà không thay đổi chi phí tính toán của các đơn vị riêng lẻ liên quan đến FLOPs. Về mặt hình thức, sự lan truyền lớp đơn trong HC được định nghĩa là:

$$x_{l+1} = \mathcal{H}_l^{res} x_l + \mathcal{H}_l^{post\top} \mathcal{F}(\mathcal{H}_l^{pre} x_l, \mathcal{W}_l) \quad (3)$$

trong đó x_l và x_{l+1} biểu thị đầu vào và đầu ra của lớp thứ l . Khác với công thức trong Phương trình (1), chiều đặc trưng của x_l và x_{l+1} được mở rộng từ C lên $n \times C$, trong đó n là tỷ lệ mở rộng. Thuật ngữ $\mathcal{H}_l^{res} \in R^{n \times n}$ đại diện cho một ánh xạ có thể học được (learnable mapping) trộn các đặc trưng trong luồng thẳng dư. Cũng là một ánh xạ có thể học được, $\mathcal{H}_l^{pre} \in R^{1 \times n}$ tổng hợp các đặc trưng từ luồng nC - chiều thành đầu vào lớp C -chiều, và ngược lại, $\mathcal{H}_l^{post} \in R^{1 \times n}$ ánh xạ đầu ra của lớp trở lại luồng.

Tuy nhiên, khi quy mô huấn luyện tăng lên, HC đưa ra những rủi ro tiềm ẩn về sự mất ổn định. Mối quan tâm chính là bản chất không bị ràng buộc của HC làm tổn hại đến tính chất ánh xạ đồng nhất khi kiến trúc mở rộng qua nhiều lớp. Mở rộng đệ quy HC sang nhiều lớp thông qua Phương trình (3) mang lại:

$$x_L = \left(\prod_{i=1}^{L-l} \mathcal{H}_{L-i}^{res} \right) x_l + \sum_{j=l}^{L-1} \left(\prod_{i=1}^{L-1-j} \mathcal{H}_{L-i}^{res} \right) \mathcal{H}_j^{post\top} \mathcal{F}(\mathcal{H}_j^{pre} x_j, \mathcal{W}_j) \quad (4)$$

Sự khác biệt này dẫn đến việc khuếch đại hoặc suy giảm tín hiệu không giới hạn, dẫn đến sự mất ổn định trong quá trình huấn luyện quy mô lớn. Hơn nữa, mặc dù HC bảo toàn hiệu quả tính toán về mặt FLOPs, hiệu quả phần cứng liên quan đến chi phí truy cập bộ nhớ cho luồng thẳng dư mở rộng vẫn chưa được giải quyết.

Để giải quyết những thách thức này, chúng tôi đề xuất **Manifold-Constrained Hyper-Connections (mHC)**, như thể hiện trong Hình 1(c), sử dụng thuật toán Sinkhorn-Knopp để chiếu entropically $\mathcal{H}_l^{res}$ lên khối đa diện Birkhoff (Birkhoff polytope). Thao tác này hạn chế các ma trận kết nối thẳng dư trong đa tạp được cấu thành bởi các ma trận ngẫu nhiên kép (doubly stochastic matrices).

2 Các nghiên cứu liên quan


Sự tiến bộ về kiến trúc trong học sâu chủ yếu có thể được phân loại thành thiết kế vi mô (micro-design) và thiết kế vĩ mô (macro-design).

2.1 Thiết kế Vi mô (Micro Design)

Được thúc đẩy bởi việc chia sẻ tham số và bất biến dịch chuyển, tích chập (convolution) ban đầu thống trị việc xử lý các tín hiệu có cấu trúc. Trong khi các biến thể sau đó như tích chập tách biệt theo độ sâu (depthwise separable) và tích chập nhóm (grouped convolutions) tối ưu hóa hiệu quả, sự ra đời của Transformers đã thiết lập Attention và Mạng Feed-Forward (FFNs) làm các khối xây dựng cơ bản của kiến trúc hiện đại. Để cân bằng hiệu suất với nhu cầu tính toán của LLMs, các cơ chế chú ý đã phát triển theo hướng các biến thể hiệu quả như Multi-Query Attention (MQA), Grouped-Query Attention (GQA), và Multi-Head Latent Attention (MLA). Đồng thời, FFNs đã được tổng quát hóa thành các mô hình tính toán thừa thớt thông qua Mixture-of-Experts (MoE).

2.2 Thiết kế Vĩ mô (Macro Design)

Thiết kế vĩ mô chi phối cấu trúc tô pô toàn cầu của mạng lưới. Theo sau ResNet, các kiến trúc như DenseNet và FractalNet nhằm mục đích nâng cao hiệu suất bằng cách tăng độ phức tạp



Hình 1: Minh họa các mô hình Kết nối Thặng dư. Hình này so sánh thiết kế cấu trúc của (a) Kết nối Thặng dư tiêu chuẩn, (b) Hyper-Connections (HC), và (c) Manifold-Constrained Hyper-Connections (mHC) được đề xuất của chúng tôi. Không giống như HC không ràng buộc, mHC tập trung vào việc tối ưu hóa không gian kết nối thặng dư bằng cách chiếu các ma trận lên một đa tạp bị ràng buộc để đảm bảo sự ổn định.

tô pô thông qua kết nối dày đặc và cấu trúc đa đường dẫn. Deep Layer Aggregation (DLA) mở rộng thêm mô hình này bằng cách tổng hợp đệ quy các đặc trưng qua các độ sâu và độ phân giải khác nhau. Gần đây hơn, trọng tâm của thiết kế vĩ mô đã chuyển sang việc mở rộng độ rộng của luồng thặng dư. Hyper-Connections (HC) giới thiệu các ma trận có thể học được để điều chỉnh cường độ kết nối giữa các đặc trưng ở các độ sâu khác nhau. Dựa trên HC, mHC được đề xuất hạn chế không gian kết nối thặng dư lên một đa tạp cụ thể để khôi phục tính chất ánh xạ đồng nhất.

3 Cơ sở lý thuyết (Preliminary)

Đầu tiên chúng tôi thiết lập các ký hiệu được sử dụng. Trong công thức HC, đầu vào cho lớp thứ l , $x_l \in R^{1 \times C}$, được mở rộng bởi một hệ số n để xây dựng một ma trận ẩn $x_l = (x_{l,0}^\top, \dots, x_{l,n-1}^\top)^\top \in R^{n \times C}$ có thể được xem như phần dư n -luồng. Thao tác này mở rộng hiệu quả độ rộng của luồng thặng dư. Để quản lý các quá trình đọc (read-out), ghi (write-in) và cập nhật của luồng này, HC giới thiệu ba ánh xạ tuyến tính có thể học được - $\mathcal{H}_l^{pre}, \mathcal{H}_l^{post} \in R^{1 \times n}$, và $\mathcal{H}_l^{res} \in R^{n \times n}$.

Trong công thức HC, các ánh xạ có thể học được bao gồm hai phần hệ số: phần phụ thuộc đầu vào và phần toàn cục, được gọi tương ứng là ánh xạ động và ánh xạ tĩnh. Cụ thể, HC tính toán các hệ số như sau:

$$\begin{aligned}
 \bar{x}_l &= \text{RMSNorm}(x_l) \\
 \mathcal{H}_l^{pre} &= \alpha_l^{pre} \cdot \tanh(\theta_l^{pre} \bar{x}_l^\top) + b_l^{pre} \\
 \mathcal{H}_l^{post} &= \alpha_l^{post} \cdot \tanh(\theta_l^{post} \bar{x}_l^\top) + b_l^{post} \\
 \mathcal{H}_l^{res} &= \alpha_l^{res} \cdot \tanh(\theta_l^{res} \bar{x}_l^\top) + b_l^{res},
 \end{aligned} \tag{5}$$

trong đó $\text{RMSNorm}(\cdot)$ được áp dụng cho chiều cuối cùng, và các vô hướng $\alpha_l^{pre}, \alpha_l^{post}$ và $\alpha_l^{res} \in R$ là các yếu tố cổng có thể học được, được khởi tạo với các giá trị nhỏ. Các ánh xạ động


được dẫn xuất thông qua các phép chiếu tuyến tính được tham số hóa bởi $\theta_l^{pre}, \theta_l^{post} \in R^{1 \times C}$ và $\theta_l^{res} \in R^{n \times C}$, trong khi các ánh xạ tính được biểu diễn bởi các bias có thể học được $b_l^{pre}, b_l^{post} \in R^{1 \times n}$ và $b_l^{res} \in R^{n \times n}$.

Điều đáng chú ý là việc giới thiệu các ánh xạ này gây ra chi phí tính toán không đáng kể, vì tỷ lệ mở rộng n điển hình (ví dụ: 4) nhỏ hơn nhiều so với kích thước đầu vào C .

3.1 Sự Mất Ổn Định Số Học (Numerical Instability)

Trong khi ánh xạ thặng dư $\mathcal{H}_l^{res}$ là công cụ quan trọng cho hiệu suất, việc áp dụng tuần tự nó đặt ra một rủi ro đáng kể đối với sự ổn định số học. Như được chi tiết trong Phương trình (4), khi HC được mở rộng qua nhiều lớp, sự lan truyền tín hiệu hiệu quả từ lớp l đến L được chi phối bởi ánh xạ tổng hợp $\prod_{i=1}^{L-l} \mathcal{H}_{L-i}^{res}$. Vì ánh xạ có thể học được $\mathcal{H}_l^{res}$ không bị ràng buộc, ánh xạ tổng hợp này chắc chắn sẽ lệch khỏi ánh xạ đồng nhất. Hậu quả là, độ lớn tín hiệu dễ bị bùng nổ hoặc biến mất trong cả quá trình lan truyền thuận (forward pass) và lan truyền ngược (backpropagation). Hiện tượng này làm suy yếu tiền đề cơ bản của việc học thặng dư, vốn dựa vào dòng tín hiệu không bị cản trở, do đó làm mất ổn định quá trình huấn luyện trong các mô hình sâu hơn hoặc quy mô lớn hơn.

Bằng chứng thực nghiệm hỗ trợ phân tích này. Chúng tôi quan sát thấy hành vi mất mát (loss) không ổn định trong các thử nghiệm quy mô lớn, như minh họa trong Hình 2. Lấy mHC làm cơ sở, HC thể hiện sự gia tăng mất mát bất ngờ vào khoảng bước thứ 12k, tương quan cao với sự mất ổn định trong chuẩn gradient (gradient norm).




Hình 2: Sự mất ổn định khi huấn luyện của Hyper-Connections (HC). Hình này minh họa (a) khoảng cách mất mát tuyệt đối của HC so với mHC, và (b) so sánh các chuẩn gradient. Tất cả kết quả đều dựa trên các mô hình 27B.

Hơn nữa, phân tích trên $\mathcal{H}_l^{res}$ xác nhận cơ chế của sự mất ổn định này. Để định lượng cách ánh xạ tổng hợp $\prod_{i=1}^{L-l} \mathcal{H}_{L-i}^{res}$ khuếch đại tín hiệu dọc theo luồng thặng dư, chúng tôi sử dụng hai số liệu. Số liệu đầu tiên, dựa trên giá trị tuyệt đối lớn nhất của tổng hàng của ánh xạ tổng hợp, nắm bắt sự mở rộng trường hợp xấu nhất trong quá trình lan truyền thuận. Số liệu thứ hai, dựa trên tổng cột tuyệt đối lớn nhất, tương ứng với quá trình lan truyền ngược. Chúng tôi gọi các số liệu này là *Amx Gain Magnitude* của ánh xạ tổng hợp. Như được hiển thị trong Hình 3(b), Amx Gain Magnitude mang lại các giá trị cực đoan với đỉnh điểm là 3000, một sự khác biệt rõ rệt so với 1, xác nhận sự hiện diện của các luồng thặng dư bùng nổ.

3.2 Chi Phí Hệ Thống (System Overhead)

Mặc dù độ phức tạp tính toán của HC vẫn có thể quản lý được do tính tuyến tính của các ánh xạ bổ sung, chi phí cấp hệ thống lại là một thách thức không nhỏ. Cụ thể, chi phí truy cập bộ nhớ (I/O) thường cấu thành một trong những điểm nghẽn chính trong các kiến trúc mô hình hiện đại, thường được gọi là "bức tường bộ nhớ" (memory wall). Điểm nghẽn này thường bị bỏ qua trong thiết kế kiến trúc, nhưng nó tác động quyết định đến hiệu quả thời gian chạy.



Hình 3: Sự mất ổn định lan truyền của Hyper-Connections (HC). Hình này minh họa động lực lan truyền của (a) ánh xạ lớp đơn $\mathcal{H}_l^{res}$ và (b) ánh xạ tổng hợp $\prod_{i=1}^{L-l} \mathcal{H}_{L-i}^{res}$ trong mô hình 27B.

Tập trung vào kiến trúc pre-norm Transformer được áp dụng rộng rãi, chúng tôi phân tích các mẫu I/O vốn có của HC. Bảng 1 tóm tắt chi phí truy cập bộ nhớ trên mỗi token trong một lớp thặng dư đơn lẻ do thiết kế thặng dư n-luồng đưa ra. Phân tích tiết lộ rằng HC làm tăng chi phí truy cập bộ nhớ một hệ số xấp xỉ tỷ lệ thuận với n . Nhu cầu I/O quá mức này làm giảm đáng kể thông lượng huấn luyện nếu không có sự giảm nhẹ của các kernel hợp nhất (fused kernels). Ngoài ra, vì $\mathcal{H}_l^{pre}$, $\mathcal{H}_l^{post}$, và $\mathcal{H}_l^{res}$ liên quan đến các tham số có thể học được, các kích hoạt trung gian của chúng là bắt buộc cho lan truyền ngược. Điều này dẫn đến sự gia tăng đáng kể dấu chân bộ nhớ GPU.

Bảng 1: So sánh Chi phí Truy cập Bộ nhớ Mỗi Token. Phân tích này tính đến chi phí do việc duy trì luồng thặng dư trong quá trình lan truyền thuận, loại trừ I/O nội bộ của hàm lớp $\mathcal{F}$.

Phương pháp	Hoạt động	Đọc (Phần tử)	Ghi (Phần tử)
Residual	Residual Merge	$2C$	C
Connection	Tổng I/O	$2C$	C
	Tính $\mathcal{H}_l^{pre}, \mathcal{H}_l^{post}, \mathcal{H}_l^{res}$	nC	$n^2 + 2n$
	$\mathcal{H}_l^{pre}$	$nC + n$	C
Hyper-	$\mathcal{H}_l^{post}$	$C + n$	nC
Connections	$\mathcal{H}_l^{res}$	$nC + n^2$	nC
	Residual Merge	$2nC$	nC
	Tổng I/O	$(5n + 1)C + n^2 + 2n$	$(3n + 1)C + n^2 + 2n$

4 Phương Pháp

4.1 Hyper-Connections Bị Ràng Buộc Đa Tập (Manifold-Constrained Hyper-Connections)

Lấy cảm hứng từ nguyên lý ánh xạ đồng nhất, tiền đề cốt lõi của mHC là hạn chế ánh xạ thặng dư $\mathcal{H}_l^{res}$ lên một đa tập cụ thể. Trong khi ánh xạ đồng nhất ban đầu đảm bảo sự ổn định bằng cách thực thi $\mathcal{H}_l^{res} = I$, nó về cơ bản ngăn cản việc trao đổi thông tin trong luồng thặng dư, điều rất quan trọng để tối đa hóa tiềm năng của các kiến trúc đa luồng. Do đó, chúng tôi đề xuất chiếu ánh xạ thặng dư lên một đa tập đồng thời duy trì sự ổn định của lan truyền tín hiệu qua các lớp và tạo điều kiện cho sự tương tác lẫn nhau giữa các luồng thặng dư để bảo tồn khả năng biểu đạt của mô hình.

Để đạt được mục tiêu này, chúng tôi hạn chế $\mathcal{H}_l^{res}$ là một ma trận ngẫu nhiên kép (doubly stochastic matrix), có các mục không âm trong đó cả tổng hàng và tổng cột đều bằng 1. Về mặt hình thức, gọi $\mathcal{M}^{res}$ là đa tập của các ma trận ngẫu nhiên kép (còn được gọi là khối đa

diện Birkhoff). Chúng tôi hạn chế $\mathcal{H}_l^{res}$ thành $\mathcal{P}_{\mathcal{M}^{res}}(\tilde{\mathcal{H}}_l^{res})$ được định nghĩa là:

$$\mathcal{P}_{\mathcal{M}^{res}}(\mathcal{H}_l^{res}) := \{\mathcal{H}_l^{res} \in R^{n \times n} \mid \mathcal{H}_l^{res} \mathbf{1}_n = \mathbf{1}_n, \mathbf{1}_n^\top \mathcal{H}_l^{res} = \mathbf{1}_n^\top, \mathcal{H}_l^{res} \geq 0\}, \quad (6)$$

trong đó $\mathbf{1}_n$ đại diện cho vectơ n chiều của tất cả các số một. Việc lựa chọn tính ngẫu nhiên kép mang lại một số tính chất lý thuyết chặt chẽ có lợi cho việc huấn luyện mô hình quy mô lớn:

1. **Bảo toàn Chuẩn (Norm Preservation):** Chuẩn phổ (spectral norm) của một ma trận ngẫu nhiên kép bị chặn bởi 1 (tức là $\|\mathcal{H}_l^{res}\|_2 \leq 1$). Điều này ngụ ý rằng ánh xạ có thể học được là không giãn nở, giảm thiểu hiệu quả vấn đề bùng nổ gradient.
2. **Đóng Kín Hợp Thành (Compositional Closure):** Tập hợp các ma trận ngẫu nhiên kép là đóng dưới phép nhân ma trận. Điều này đảm bảo rằng ánh xạ thặng dư hợp nhất qua nhiều lớp, $\prod_{i=1}^{L-l} \mathcal{H}_{L-i}^{res}$, vẫn là ngẫu nhiên kép, do đó bảo tồn sự ổn định trong suốt toàn bộ độ sâu của mô hình.
3. **Giải Thích Hình Học qua Khối Đa Diện Birkhoff:** Tập hợp $\mathcal{M}^{res}$ tạo thành khối đa diện Birkhoff, là bao lồi của tập hợp các ma trận hoán vị. Điều này cung cấp một giải thích hình học rõ ràng: ánh xạ thặng dư hoạt động như một tổ hợp lồi của các hoán vị. Về mặt toán học, việc áp dụng lặp đi lặp lại các ma trận như vậy có xu hướng tăng sự trộn lẫn thông tin qua các luồng một cách đơn điệu.

Ngoài ra, chúng tôi áp đặt các ràng buộc không âm đối với các ánh xạ đầu vào $\mathcal{H}_l^{pre}$ và ánh xạ đầu ra $\mathcal{H}_l^{post}$. Ràng buộc này ngăn chặn việc triệt tiêu tín hiệu phát sinh từ sự kết hợp của các hệ số dương và âm.

4.2 Tham Số Hóa và Chiếu Đa Tập

Trong phần này, chúng tôi chi tiết hóa quy trình tính toán của $\mathcal{H}_l^{pre}$, $\mathcal{H}_l^{post}$, và $\mathcal{H}_l^{res}$ trong mHC. Với ma trận ẩn đầu vào $x_l \in R^{n \times C}$ tại lớp thứ l , trước tiên chúng tôi làm phẳng nó thành một vectơ $\tilde{x}_l = \text{vec}(x_l) \in R^{1 \times nC}$ để bảo toàn thông tin ngữ cảnh đầy đủ. Sau đó, chúng tôi tuân theo công thức HC ban đầu để có được các ánh xạ động và ánh xạ tĩnh như sau:

$$\begin{aligned} \tilde{x}_l' &= \text{RMSNorm}(\tilde{x}_l) \\ \tilde{\mathcal{H}}_l^{pre} &= \alpha_l^{pre} \cdot (\tilde{x}_l' \varphi_l^{pre}) + b_l^{pre} \\ \tilde{\mathcal{H}}_l^{post} &= \alpha_l^{post} \cdot (\tilde{x}_l' \varphi_l^{post}) + b_l^{post} \\ \tilde{\mathcal{H}}_l^{res} &= \alpha_l^{res} \cdot \text{mat}(\tilde{x}_l' \varphi_l^{res}) + b_l^{res}, \end{aligned} \quad (7)$$

trong đó $\varphi_l^{pre}, \varphi_l^{post} \in R^{nC \times n}$ và $\varphi_l^{res} \in R^{nC \times n^2}$ là các phép chiếu tuyến tính. Sau đó, các ánh xạ bị ràng buộc cuối cùng thu được thông qua:

$$\begin{aligned} \mathcal{H}_l^{pre} &= \sigma(\tilde{\mathcal{H}}_l^{pre}) \\ \mathcal{H}_l^{post} &= 2\sigma(\tilde{\mathcal{H}}_l^{post}) \\ \mathcal{H}_l^{res} &= \text{Sinkhorn-Knopp}(\exp(\tilde{\mathcal{H}}_l^{res})), \end{aligned} \quad (8)$$

trong đó $\sigma(\cdot)$ biểu thị hàm Sigmoid. Toán tử Sinkhorn-Knopp() trước tiên làm cho tất cả các phần tử trở thành dương thông qua một toán tử số mũ và sau đó thực hiện quy trình chuẩn hóa lặp đi lặp lại luân phiên thay đổi tỷ lệ các hàng và cột để tổng bằng 1. Cụ thể, với ma trận dương $M^{(0)} = \exp(\tilde{\mathcal{H}}_l^{res})$ làm điểm bắt đầu, vòng lặp chuẩn hóa tiến hành như sau:

$$M^{(t)} = \mathcal{T}_c(\mathcal{T}_r(M^{(t-1)})), \quad (9)$$

trong đó $\mathcal{T}_r$ và $\mathcal{T}_c$ biểu thị chuẩn hóa hàng và cột tương ứng. Quá trình này hội tụ về một ma trận ngẫu nhiên kép khi $t_{max} \rightarrow \infty$. Chúng tôi chọn $t_{max} = 20$ làm giá trị thực tế trong các thử nghiệm của mình.

4.3 Thiết Kế Cơ Sở Hạ Tầng Hiệu Quả

4.3.1 Hợp Nhất Kernel (Kernel Fusion)

Quan sát thấy rằng RMSNorm trong mHC áp đặt độ trễ đáng kể khi hoạt động trên trạng thái ẩn chiều cao $\vec{x}_l \in R^{1 \times nC}$, chúng tôi sắp xếp lại hoạt động chia cho chuẩn (dividing-by-norm) để theo sau phép nhân ma trận. Tối ưu hóa này duy trì sự tương đương toán học trong khi cải thiện hiệu quả. Hơn nữa, chúng tôi sử dụng các chiến lược độ chính xác hỗn hợp (mixed-precision) để tối đa hóa độ chính xác số học mà không ảnh hưởng đến tốc độ, và hợp nhất nhiều hoạt động có truy cập bộ nhớ chia sẻ thành các hạt nhân tính toán thống nhất.

Dựa trên các đầu vào và tham số được chi tiết trong Phương trình (10) đến (13), chúng tôi triển khai ba kernel mHC chuyên biệt để tính toán $\mathcal{H}_l^{pre}$, $\mathcal{H}_l^{post}$, và $\mathcal{H}_l^{res}$. Trong các kernel này, các bias và phép chiếu tuyến tính được hợp nhất thành b_l và φ_l .

$$\varphi_l : \text{tfloat32} \quad [nC, n^2 + 2n] \quad (10)$$

$$b_l : \text{float32} \quad [1, n^2 + 2n] \quad (11)$$

$$\alpha_l^{pre}, \alpha_l^{post}, \alpha_l^{res} : \text{float32} \quad \text{Scalars} \quad (12)$$

$$\vec{x}_l : \text{bfloat16} \quad [1, nC] \quad (13)$$

$$[\tilde{\mathcal{H}}_l^{pre}, \tilde{\mathcal{H}}_l^{post}, \tilde{\mathcal{H}}_l^{res}] : \text{float32} = \vec{x}_l \varphi_l \quad (14)$$

$$r : \text{float32} = \|\vec{x}_l\|_2 / \sqrt{nC} \quad (15)$$

$$[\tilde{\mathcal{H}}_l^{pre}, \tilde{\mathcal{H}}_l^{post}, \tilde{\mathcal{H}}_l^{res}] : \text{float32} = \frac{1}{r} [\alpha_l^{pre} \tilde{\mathcal{H}}_l^{pre}, \alpha_l^{post} \tilde{\mathcal{H}}_l^{post}, \alpha_l^{res} \tilde{\mathcal{H}}_l^{res}] + b_l \quad (16)$$

$$\mathcal{H}_l^{pre} : \text{float32} = \sigma(\tilde{\mathcal{H}}_l^{pre}) \quad (17)$$

$$\mathcal{H}_l^{post} : \text{float32} = 2\sigma(\tilde{\mathcal{H}}_l^{post}) \quad (18)$$

$$\mathcal{H}_l^{res} : \text{float32} = \text{Sinkhorn-Knopp}(\exp(\tilde{\mathcal{H}}_l^{res})) \quad (19)$$

Sử dụng các hệ số từ các kernel nói trên, chúng tôi giới thiệu thêm hai kernel nữa để áp dụng các ánh xạ này: một cho $\mathcal{F}_{pre} := \mathcal{H}_l^{pre} x_l$ và một cho $\mathcal{F}_{post, res} := \mathcal{H}_l^{res} x_l + \mathcal{H}_l^{post \top} \mathcal{F}(\cdot, \cdot)$. Thông qua việc hợp nhất ứng dụng của $\mathcal{H}_l^{post}$ và $\mathcal{H}_l^{res}$ với việc hợp nhất thẳng dư, chúng tôi giảm số lượng phần tử đọc và ghi đáng kể. Chúng tôi triển khai hiệu quả phần lớn các kernel (ngoại trừ Eq. 14 đến 15) sử dụng TileLang.

4.3.2 Tính Toán Lại (Recomputing)

Thiết kế thẳng dư n -luồng giới thiệu chi phí bộ nhớ đáng kể trong quá trình huấn luyện. Để giảm thiểu điều này, chúng tôi loại bỏ các kích hoạt trung gian của các kernel mHC sau quá trình lan truyền thuận và tính toán lại chúng ngay lập tức (on-the-fly) trong quá trình lan truyền ngược, thông qua việc thực thi lại các kernel mHC mà không có hàm lớp nặng $\mathcal{F}$. Do đó, đối với một khối gồm L_r lớp liên tiếp, chúng tôi chỉ cần lưu trữ đầu vào x_{l_0} cho lớp đầu tiên.

Vì việc tính toán lại các kernel mHC được thực hiện cho các khối gồm L_r lớp liên tiếp, với tổng số L lớp, chúng tôi phải lưu trữ liên tục đầu vào lớp đầu tiên x_{l_0} cho tất cả $\lceil L/L_r \rceil$ khối cho quá trình lan truyền ngược. Ngoài bộ nhớ thường trú này, quá trình tính toán lại giới thiệu

một chi phí bộ nhớ tạm thời là $(n+2)C \times L_r$ phần tử cho khối đang hoạt động, xác định mức sử dụng bộ nhớ đỉnh trong quá trình lan truyền ngược. Do đó, chúng tôi xác định kích thước khối tối ưu L_r^* bằng cách giảm thiểu tổng dấu chân bộ nhớ tương ứng với L_r :


$$L_r^* = \arg \min_{L_r} \left[nC \times \left\lceil \frac{L}{L_r} \right\rceil + (n+2)C \times L_r \right] \approx \sqrt{\frac{nL}{n+2}}. \quad (20)$$

Hơn nữa, song song hóa đường ống (pipeline parallelism) trong huấn luyện quy mô lớn áp đặt một ràng buộc: các khối tính toán lại không được vượt qua ranh giới giai đoạn đường ống. Quan sát thấy rằng L_r^* tối ưu về mặt lý thuyết thường phù hợp với số lượng lớp trên mỗi giai đoạn đường ống, chúng tôi chọn đồng bộ hóa các ranh giới tính toán lại với các giai đoạn đường ống.

4.3.3 Chồng Lấp Giao Tiếp trong DualPipe (Overlapping Communication in DualPipe)

Trong huấn luyện quy mô lớn, song song hóa đường ống là thực tiễn tiêu chuẩn để giảm thiểu dấu chân bộ nhớ tham số và gradient. Cụ thể, chúng tôi áp dụng lịch trình DualPipe, giúp chồng lấp hiệu quả lưu lượng giao tiếp liên kết mở rộng quy mô, chẳng hạn như trong song song hóa chuyên gia (expert parallelism) và đường ống. Tuy nhiên, so với thiết kế luồng đơn, thặng dư n -luồng được đề xuất trong mHC phát sinh độ trễ giao tiếp đáng kể qua các giai đoạn đường ống. Hơn nữa, tại các ranh giới giai đoạn, việc tính toán lại các kernel mHC cho tất cả L_r lớp giới thiệu chi phí tính toán không nhỏ.

Để giải quyết những điểm nghẽn này, chúng tôi mở rộng lịch trình DualPipe (xem Hình 4) để tạo điều kiện cải thiện việc chồng lấp giao tiếp và tính toán tại các ranh giới giai đoạn đường ống.



Hình 4: Chồng lấp Giao tiếp-Tính toán cho mHC. Chúng tôi mở rộng lịch trình DualPipe để xử lý chi phí do mHC đưa ra. Độ dài của mỗi khối chỉ mang tính minh họa.

Đáng chú ý, để ngăn chặn việc chặn luồng giao tiếp, chúng tôi thực thi các kernel $\mathcal{F}_{post, res}$ của các lớp MLP (tức là FFN) trên một luồng tính toán ưu tiên cao chuyên dụng. Chúng tôi cũng hạn chế sử dụng các kernel liên tục cho các hoạt động chạy lâu trong các lớp attention, do đó ngăn chặn các khoảng dừng kéo dài. Thiết kế này cho phép chiếm dụng trước các tính toán attention chồng lấp, cho phép lập lịch linh hoạt trong khi duy trì hiệu suất sử dụng cao của các đơn vị xử lý thiết bị tính toán.

5 Thực Nghiệm


5.1 Thiết Lập Thực Nghiệm

Chúng tôi xác thực phương pháp đề xuất thông qua việc huấn luyện trước mô hình ngôn ngữ, tiến hành phân tích so sánh giữa đường cơ sở (baseline), HC và mHC được đề xuất của chúng tôi[cite: 371]. Sử dụng kiến trúc MoE lấy cảm hứng từ DeepSeek-V3, chúng tôi huấn luyện bốn biến thể mô hình khác nhau để bao phủ các chế độ đánh giá khác nhau[cite: 372]. Cụ thể, tỷ lệ mở rộng n cho cả HC và mHC được đặt là 4. Trọng tâm chính của chúng tôi là mô hình 27B được huấn luyện với kích thước tập dữ liệu tỷ lệ thuận với các tham số của nó[cite: 373]. Mở rộng điều này, chúng tôi phân tích hành vi mở rộng quy mô tính toán bằng cách kết hợp các

mô hình nhỏ hơn 3B và 9B được huấn luyện với dữ liệu tỷ lệ, cho phép chúng tôi quan sát xu hướng hiệu suất qua các mức tính toán khác nhau[cite: 374]. Ngoài ra, để điều tra cụ thể hành vi mở rộng token, chúng tôi huấn luyện một mô hình 3B riêng biệt trên một kho ngữ liệu cố định gồm 1 nghìn tỷ token[cite: 375].

5.2 Kết Quả Chính

Chúng tôi bắt đầu bằng việc kiểm tra độ ổn định huấn luyện và sự hội tụ của các mô hình 27B[cite: 407]. Như được minh họa trong Hình 5(a), mHC giảm thiểu hiệu quả sự mất ổn định huấn luyện quan sát được trong HC, đạt được mức giảm mất mát cuối cùng là 0.021 so với đường cơ sở[cite: 408]. Sự ổn định được cải thiện này được chứng thực thêm bởi phân tích chuẩn gradient trong Hình 5(b), trong đó mHC thể hiện hành vi tốt hơn đáng kể so với HC, duy trì hồ sơ ổn định tương đương với đường cơ sở[cite: 409].



Hình 5: Độ ổn định huấn luyện của Manifold-Constrained Hyper-Connections (mHC). Hình này minh họa (a) khoảng cách mất mát huấn luyện tuyệt đối của mHC và HC so với đường cơ sở, và (b) chuẩn gradient của ba phương pháp.


Bảng 2 trình bày hiệu suất hạ nguồn trên một tập hợp đa dạng các tiêu chuẩn đánh giá [cite: 414]. mHC mang lại những cải tiến toàn diện, liên tục vượt qua đường cơ sở và vượt qua HC trên phần lớn các tác vụ[cite: 415]. Đáng chú ý, so với HC, mHC tăng cường thêm khả năng suy luận của mô hình, mang lại mức tăng hiệu suất 2.1% trên BBH và 2.3% trên DROP[cite: 416].

Bảng 2: Kết quả Benchmark cấp hệ thống cho các Mô hình 27B. Bảng này so sánh hiệu suất zero-shot và few-shot của Baseline, HC và mHC trên 8 benchmark hạ nguồn đa dạng.

Benchmark	Metric	Shots	27B Baseline	27B w/ HC	27B w/ mHC
BBH	EM	3-shot	43.8	48.9	51.0
DROP	F1	3-shot	47.0	51.6	53.9
HellaSwag	Acc.	10-shot	73.7	74.3	74.7
GSM8K	EM	4-shot	46.7	53.2	53.8
MATH	EM	4-shot	22.0	26.4	26.0
MMLU	Acc.	5-shot	59.0	63.0	63.4
PIQA	Acc.	0-shot	78.5	79.9	80.5
TriviaQA	EM	5-shot	54.3	56.3	57.6

5.3 Thử Nghiệm Mở Rộng Quy Mô (Scaling Experiments)


Để đánh giá khả năng mở rộng của phương pháp tiếp cận của chúng tôi, chúng tôi báo cáo sự cải thiện mất mát tương đối của mHC so với đường cơ sở qua các quy mô khác nhau[cite: 470]. Trong Hình 6(a), chúng tôi vẽ đường cong mở rộng tính toán trải dài qua các tham số 3B, 9B và 27B[cite: 471]. Quỹ đạo chỉ ra rằng lợi thế hiệu suất được duy trì mạnh mẽ ngay cả ở ngân sách tính toán cao hơn, chỉ cho thấy sự suy giảm biên[cite: 472]. Hơn nữa, chúng tôi kiểm tra động lực trong quá trình chạy ở Hình 6(b), trình bày đường cong mở rộng token cho mô hình 3B[cite: 473].



Hình 6: Các đặc tính mở rộng của mHC so với Đường cơ sở. (a) Đường cong mở rộng Tính toán. (b) Đường cong mở rộng Token.

5.4 Phân Tích Độ Ổn Định (Stability Analysis)


Tương tự như Hình 3, Hình 7 minh họa độ ổn định lan truyền của mHC[cite: 540]. Lý tưởng nhất, ánh xạ lớp đơn thỏa mãn ràng buộc ngẫu nhiên kép, ngụ ý rằng cả độ lợi tín hiệu thuận (forward signal gain) và độ lợi gradient ngược (backward gradient gain) đều phải bằng 1. Tuy nhiên, các triển khai thực tế sử dụng thuật toán Sinkhorn-Knopp phải giới hạn số lần lặp để đạt hiệu quả tính toán[cite: 541]. Trong các cài đặt của chúng tôi, chúng tôi sử dụng 20 lần lặp để thu được giải pháp gần đúng[cite: 542].



Hình 7: Độ ổn định lan truyền của Manifold-Constrained Hyper-Connections (mHC). Hình này minh họa động lực lan truyền của (a) ánh xạ lớp đơn và (b) ánh xạ tổng hợp trong mô hình 27B.

Hậu quả là, như được hiển thị trong Hình 7(a), độ lợi gradient ngược lệch một chút so với 1[cite: 543]. Trong trường hợp tổng hợp được hiển thị trong Hình 7(b), độ lệch tăng lên nhưng vẫn bị giới hạn, đạt giá trị tối đa khoảng 1.6[cite: 543]. Đáng chú ý, so với độ lớn độ lợi tối đa gần 3000 trong HC, mHC giảm đáng kể nó đi ba bậc độ lớn[cite: 544]. Những kết quả này

chứng minh rằng mHC tăng cường đáng kể độ ổn định lan truyền so với HC. Ngoài ra, Hình 8 hiển thị các ánh xạ đại diện.



Hình 8: Trực quan hóa các Ánh xạ Có thể học được. Hình này hiển thị các ánh xạ lớp đơn và tổng hợp đại diện cho HC (hàng đầu tiên) và mHC (hàng thứ hai).

5.5 Phân Tích Độ Ổn Định (Stability Analysis)

Tương tự như Hình 7, chúng tôi minh họa độ ổn định lan truyền của mHC. Lý tưởng nhất, ánh xạ lớp đơn thỏa mãn ràng buộc ngẫu nhiên kép, ngụ ý rằng cả độ lợi tín hiệu thuận (forward signal gain) và độ lợi gradient ngược (backward gradient gain) đều phải bằng 1. Tuy nhiên, các triển khai thực tế sử dụng thuật toán Sinkhorn-Knopp phải giới hạn số lần lặp để đạt hiệu quả tính toán. Trong các cài đặt của chúng tôi, chúng tôi sử dụng 20 lần lặp để thu được giải pháp gần đúng.

6 Kết Luận và Triển Vọng

Trong bài báo này, chúng tôi xác định rằng mặc dù việc mở rộng độ rộng của luồng thẳng dư và đa dạng hóa các kết nối mang lại hiệu suất tăng như được đề xuất trong Hyper-Connections (HC), bản chất không bị ràng buộc của các kết nối này dẫn đến sự phân kỳ tín hiệu. Sự gián đoạn này làm tổn hại đến việc bảo toàn năng lượng tín hiệu qua các lớp, gây ra sự mất ổn định khi huấn luyện và cản trở khả năng mở rộng của các mạng sâu.

Để giải quyết những thách thức này, chúng tôi giới thiệu Manifold-Constrained Hyper-Connections (mHC), một khung tổng quát chiếu không gian kết nối thẳng dư lên một đa tạp cụ thể. Bằng cách sử dụng thuật toán Sinkhorn-Knopp để thực thi ràng buộc ngẫu nhiên kép (doubly stochastic) lên các ánh xạ thẳng dư, mHC chuyển đổi sự lan truyền tín hiệu thành một tổ hợp lồi của các đặc trưng. Kết quả thực nghiệm xác nhận rằng mHC khôi phục hiệu quả tính chất ánh xạ đồng nhất, cho phép huấn luyện quy mô lớn ổn định với khả năng mở rộng vượt trội so với HC thông thường. Quan trọng là, thông qua các tối ưu hóa cấp cơ sở hạ tầng hiệu quả, mHC mang lại những cải tiến này với chi phí tính toán không đáng kể.

Là một phần mở rộng tổng quát của mô hình HC, mHC mở ra một số hướng đi hứa hẹn cho nghiên cứu trong tương lai. Mặc dù công trình này sử dụng các ma trận ngẫu nhiên kép để đảm bảo sự ổn định, khung này cho phép khám phá các ràng buộc đa tạp đa dạng được điều chỉnh cho các mục tiêu học tập cụ thể. Chúng tôi dự đoán rằng việc điều tra sâu hơn về các ràng buộc hình học riêng biệt có thể mang lại các phương pháp mới giúp tối ưu hóa tốt hơn sự đánh đổi giữa tính dẻo (plasticity) và tính ổn định. Hơn nữa, chúng tôi hy vọng mHC sẽ khơi dậy sự quan tâm của cộng đồng đối với thiết kế kiến trúc vĩ mô. Bằng cách làm sâu sắc thêm sự hiểu biết về cách các cấu trúc tô pô ảnh hưởng đến việc tối ưu hóa và học biểu diễn, mHC

sẽ giúp giải quyết các hạn chế hiện tại và có khả năng soi sáng những con đường mới cho sự phát triển của các kiến trúc nền tảng thế hệ tiếp theo.